

1. CAC 3040 - VISÃO COMPUTACIONAL EM ROBÓTICA

LABORATÓRIO 2

ALVARO VINICIUS GUILHEM
MATRÍCULA: 210201099
HENRIQUE AGUIRRE SIGWALT
MATRÍCULA: 21200740

Descrição da atividade 1

O segundo laboratório realizado na disciplina de Visão Computação em Robótica foi seccionado em duas atividades. Primeiramente a atividade 1 será descrita abaixo.

Atividade 1: Desenvolver a própria função de filtragem 2D e realizar a escolha de um kernel para a suavização de uma tatuagem. As imagens de entrada e saída esperada estão representadas pela Figura 1.



Figura 1: Imagem de entrada e saída desejadas

Descrição do algoritmo da Atividade 1

Para a suavização apenas da área da tatuagem, primeiramente foram escolhidas coordenadas para delimitar uma região retangular da imagem a ser afetada, como exemplificado na Figura 2.



Figura 2: Imagem filtrada apenas na região de interesse

Em sequência, para o desenvolvimento do kernel, foi escolhido uma cor de referência para representar a pele em torno da tatuagem. Com base nisso, a cada iteração da filtragem são calculadas as distâncias das cores de cada pixel da janela W para a cor de referência, tomando a menor como alvo. Desse modo, o kernel é então calculado para que após sua aplicação a cor do pixel central seja a mais próxima possível do alvo, substituindo a tatuagem por uma cor similar à da pele do indivíduo na região. Por fim, é utilizado um laço de repetição duplo para aplicação do kernel descrito em cada um dos pixels de interesse. Para a escolha do tamanho da janela, foram feitos diversos testes com valores diferentes para h , representados na Figura 3. Com base nisso, foi concluído que tamanhos menores para a janela obtinham resultados mais naturais, resultando na escolha de $h=1$.



Figura 3: Resultados com valores de h igual a 1, 2 e 3 respectivamente

Resultados obtidos para a Atividade 1

Utilizando o algoritmo descrito na seção anterior, para uma cor de referência BGR de [160, 160, 180], foi obtido o resultado observado na Figura 4.



Figura 4: Imagem de entrada e saída do algoritmo desenvolvido.

Com isso, pode-se verificar que o código foi capaz de suavizar a tatuagem, porém não apagou a figura totalmente. Isso deve-se principalmente a regiões onde a janela não compreende cores muito próximas a referência, impedindo que o kernel elimine perfeitamente a tatuagem.

Descrição da atividade 2

Na segunda atividade do laboratório, espera-se implementar o algoritmo de detecção de bordas de Canny, bastante utilizado em visão computacional por sua eficiência em identificar contornos de forma confiável.

Atividade 2: Desenvolver uma função que implemente o algoritmo de Canny, recebendo, entre outros argumentos citados na seção de Resultados, a imagem de entrada, e retornando como saída uma imagem binária contendo as bordas detectadas. As imagens de entrada e saída esperada estão representadas pela Figura 5




Figura 5: a) imagem de entrada. b) Imagem de saída esperada.

Descrição do algoritmo da Atividade 2

O algoritmo de Canny pode ser dividido em cinco etapas principais: **Suavização Gaussiana, Cálculo do Gradiente, Supressão de Não-Máximos, Limiarização Dupla e Análise de Conectividade.**

Suavização Gaussiana

Nessa etapa, é utilizada a técnica de suavização por meio da implementação de um **Filtro Gaussiano**. Essa configuração de filtro é responsável por reduzir componentes de alta frequência da imagem, como ruídos e texturas, funcionando como um passa-baixa e tem como objetivo preparar a imagem para as etapas seguintes.

Para garantir uma transição suave e isotrópica da imagem, é utilizado um kernel 2D. Este kernel realiza a distribuição gaussiana (normal) bidimensional, apresentada na Figura 6, em que valores mais altos se concentram no centro e decaem suavemente às extremidades.




Figura 6: Distribuição Gaussiana 2D. Fonte: The University of Edinburgh.

Dessa forma, o valor de cada pixel da imagem é recalculado com base na média ponderada dos pixels de sua vizinhança, preservando estruturas maiores na imagem e reduzindo ruídos, criando um efeito de desfoque. O cálculo do kernel gaussiano discretizado segue a Equação (1), em que as variáveis j e i representam, respectivamente, o deslocamento no eixo vertical e horizontal do kernel

$$K[j, i] = \frac{1}{2\pi\sigma^2} e^{-\frac{j^2+i^2}{2\sigma^2}} \quad (1)$$

O parâmetro σ é referente ao desvio padrão necessário para a distribuição gaussiana, definindo o grau de suavização: valores maiores resultam em maior turbidez e bordas mais espessas, enquanto valores menores preservam detalhes finos, mas aumentam a sensibilidade ao ruído. Dessa forma, σ será um dos argumentos de entrada para a função Canny.

A Figura 7 demonstra a comparação entre a imagem de entrada e a imagem suavizada pelo filtro gaussiano.



(a)



(b)

Figura 7: a) Imagem de entrada. b) Imagem suavizada.

Cálculo do Gradiente

Após a suavização, a próxima etapa do algoritmo de Canny consiste no cálculo do **Gradiente** da imagem, cujo objetivo é identificar as regiões de maior variação de intensidade, que normalmente correspondem às bordas. O gradiente é obtido pelas derivadas parciais em relação aos eixos x e y da imagem suavizada I_s .

Tais derivadas foram aproximadas por meio da filtragem com os Operadores de Sobel, definidos pelos kernels K_x e K_y . O Operador de Sobel é uma máscara 3×3 que enfatiza variações de intensidade em uma direção específica, e apresenta a seguinte configuração demonstrada pela Equação (2):

$$\mathbf{K}_y = \mathbf{K}_x^T = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} \quad (2)$$

A relação entre as derivadas parciais do gradiente e os operadores de Sobel é dada pela Equação (3), em que ∇I_s representa o gradiente de fluxo da imagem suavizada, e $*$ representa a operação de convolução

$$\nabla I_s = \left(\frac{dI_s}{dx}, \frac{dI_s}{dy} \right) = (I_s * K_x, I_s * K_y) \quad (3)$$

A partir desses resultados, é possível calcular a **Magnitude (M)** e a **Direção (α)** do gradiente, representado na Equação (4) e Equação (5), respectivamente:

$$M[y, x] = \sqrt{\left(\frac{dI_s}{dx} \right)^2 + \left(\frac{dI_s}{dy} \right)^2} \quad (4)$$

$$\alpha[y, x] = \text{atan}\left(\left(\frac{dI_s[y,x]}{dy}\right) / \left(\frac{dI_s[y,x]}{dx}\right)\right) \quad (5)$$

As imagens $M[y, x]$ e $\alpha[y, x]$, dadas por tais equação, correspondem à Figura 8 e Figura 9, respectivamente.




Figura 8: Imagem $M[y, x]$.




Figura 9: Imagem $\alpha[y,x]$.

Supressão de Não-Máximos

Na etapa de Supressão de Não-Máximos (NMS), a direção do gradiente é utilizada para definir como serão realizadas as comparações entre pixels vizinhos. O ângulo α de cada pixel é associado à faixa angular de referência ilustrada na Figura 10, que quantiza a direção do gradiente em oito orientações principais, definidas entre os intervalos de cada limite angular.

Partindo disso, comparado de uma orientação principal com sua orientação oposta, conforme a Figura 11. Para cada pixel, verifica-se se sua magnitude é maior ou igual à de seu vizinho oposto na direção escolhida. Se for um pico local, o pixel é

mantido, indicando uma borda provável. Caso contrário, é descartado, pois não representa uma transição significativa. O resultado final esperado é o afinamento das bordas e a remoção de duplicatas paralelas, garantindo contornos mais limpos e precisos.




Figura 10:

Representação da faixa angular de referência.




Figura 11: Representação esperada da comparação de magnitude entre pixels vizinhos opostos.

Dessa forma, a imagem obtida após a implementação do processo NMS é exibido pela Figura 12.




Figura 12: Imagem obtida após a Supressão de Não-Máximos.

Limiarização Dupla

Esta etapa é responsável por classificar os pixels restantes conforme a intensidade de suas magnitudes. Nesse processo, são definidos dois valores de limiar: um **limiar superior** e um **limiar inferior**. Esses parâmetros determinam os níveis de confiança para que um pixel seja considerado parte de uma borda.

Com base nesses limiares, são geradas duas imagens binárias: a primeira, GNH, contém apenas os pixels cuja magnitude é maior ou igual ao limiar superior (bordas fortes). A segunda, GNL, é composta por todos os pixels cuja magnitude é maior ou igual ao limiar inferior (bordas fortes e fracas). Nesse estágio, todos os pixels presentes em GNH também estão contidos em GNL, porém em menor

quantidade. A Figura 13 exibe um exemplo de cada uma das imagens geradas, após os limiares serem definidos.




Figura 13: a) Imagem GNH. b) Imagem GNL.

Em seguida, remove-se de GNL os pixels que já estão presentes em GNH, por meio da operação diádica da Equação (6).

$$G_{NL} = G_{NL} - G_{NH}. \quad (6)$$

Esse procedimento separa as regiões de borda fraca das de borda forte, permitindo o refinamento posterior. A nova imagem GNL, após tal operação, é exibida pela Figura 14.




Figura 14: Imagem GNL pós operação diádica.

Ao final dessa etapa, os pixels de GNH são considerados bordas válidas, enquanto os de GNL ainda precisam passar pela análise de conectividade, que decidirá quais desses pixels fracos também pertencem a bordas reais da imagem.

Análise de Conectividade.

A etapa de análise de conectividade tem como objetivo validar os pixels de borda classificados anteriormente como fracos durante a limiarização dupla. Isso é feito verificando se esses pixels estão conectados a alguma borda forte, garantindo que apenas os contornos contínuos e coerentes sejam mantidos na imagem final.

Para isso, o algoritmo percorre todos os pixels de borda presentes na imagem GNH (borda forte). Para cada um desses pixels, é analisada um kernel 3×3 correspondente na imagem GNL (borda fraca). Caso dentro dessa vizinhança existam pixels brancos em GNL, eles são considerados bordas válidas, pois estão conectados a um ponto de alta confiança em GNH.

Após varrer toda a imagem, todos os pixels de GNL que não apresentarem ligação com bordas fortes são descartados (definidos como zero). A imagem final de bordas, exibida pela Figura 15, é obtida unindo as bordas fortes confirmadas com as bordas fracas validadas. pela seguinte operação diádica da Equação (7):

$$I_b = G_{NH} + G_{NL}. \quad (7)$$

Resultados obtidos para a Atividade 2

De acordo com o objetivo de desenvolver uma função que implemente o algoritmo de Canny, do qual deve receber como argumentos de entrada: (i) uma imagem de entrada em escala de cinza; (ii) o desvio padrão σ do filtro gaussiano, utilizado na etapa de suavização; (iii) o limiar superior; e (iv) o limiar inferior, empregados no processo de limiarização dupla. Como argumento de saída, a imagem de borda I_b , a seguinte Imagem foi obtida:




Figura 15: Imagem de saída Ib

Com base nos resultados obtidos, observa-se que o objetivo proposto foi atingido. A função implementada executou corretamente todas as etapas do algoritmo de Canny, produzindo uma imagem de borda nítida. Dessa forma, o comportamento obtido confirma a eficiência do método aplicado e a fidelidade da implementação em relação ao funcionamento teórico do algoritmo de Canny.